



# GAN Deep Learning



ING-3

SCIA - G

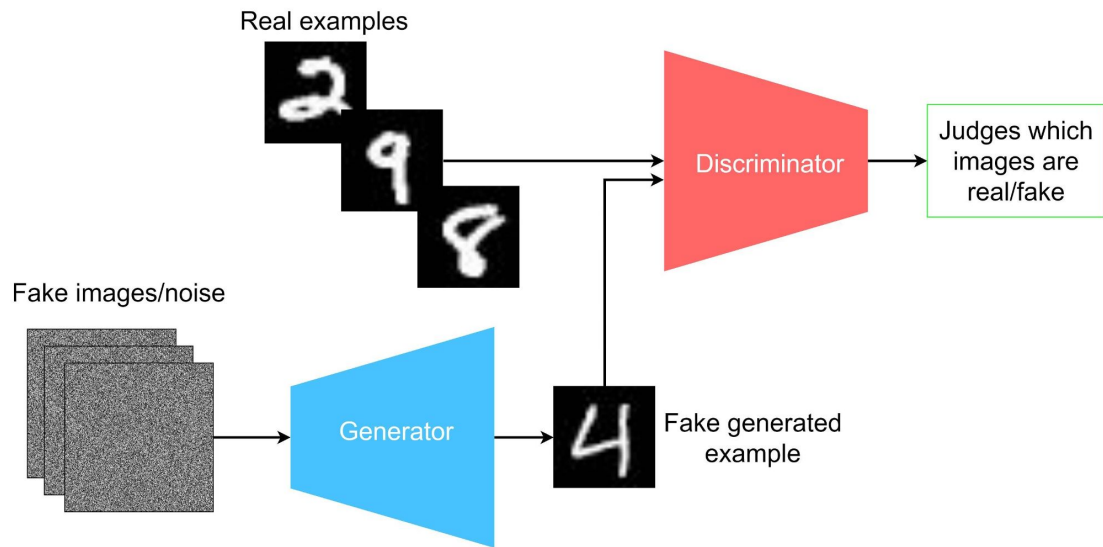
Cardi Julien  
Ferroni Sandro  
Moyo Kamdem Auren



# Plan :

1. Generative Adversarial Nets - GAN
2. Datasets
3. Modélisation
4. Résultats
5. Conclusions

# 1. Generative Adversarial Nets - GAN



# 1. Generative Adversarial Nets - GAN


- Objectif : **équilibre de Nash**

- Générateur trompe le Discriminateur

- Générateur se stabilise



- Discriminateur donne une probabilité de 0.5 à chaque image

- Jeu à somme nulle



## 2. Datasets

- **MNIST** : dataset d'images de chiffres manuscrits (28x28 en niveaux de gris)
- **FashionMNIST** : images d'articles de mode (28x28 en niveaux de gris)
- **CIFAR10** : 10 types d'images (bateaux, avions, oiseaux, ...) (32x32 RGB)




### 3. Modélisation


- **Générateur** : Linear, LeakyReLu, Linear, LeakyReLu, Linear, Tanh
- **Discriminateur** : Linear, LeakyReLu, Dropout, Maxout, Dropout, Linear, Sigmoid
- **Entraînement** : Pour chaque époque :
  - on entraîne  $k$  fois **Discriminateur** et 1 fois **Générateur**
  - **Générateur** cherche à minimiser  $\log(1 - D(G(z)))$ , mais pour les 5 premiers époques  $\rightarrow$  maximiser  $\log(D(G(z))) \rightarrow$  éviter saturation
- Possibilité de changer des hyperparamètres : batch, epoch, learning rate

## 4. Résultats MNIST

real →




fake →





## 4. Résultats

### FashionMNIST

real →




fake →






## 4. Résultats CIFAR10

real →



fake →



## 5. Conclusions

- Résultats cohérents → génération d'images
- Limité par nos PC : efficace sur de simple dataset, impossibilité de faire de nombreux essais
- Améliorations possibles : essayer d'autres hyperparamètres, faire varier les couches, trouver des algorithmes inspirés de GAN plus performants





# MERCI

Github : <https://github.com/CirSandro/DeepLearning-GAN>